Programação para Ciência de Dados



Roberto M. Cesar Jr. - rmcesar@usp.br

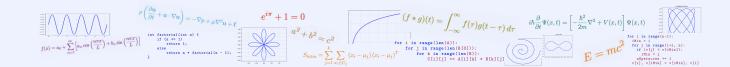




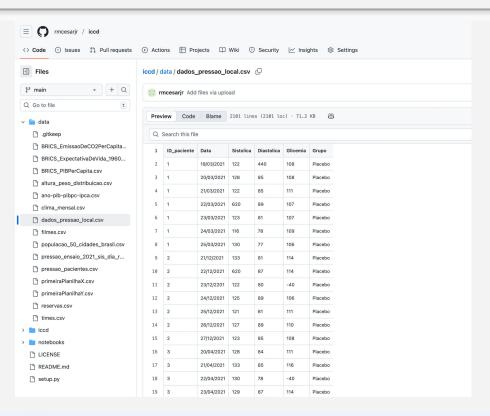
Etapas típicas de um pipeline de CD

- Datasets
- Carregamento de dados (data_loaders)
- Representação dos dados
- Tabela sumária de dados
- Manipulação de dados
- Filtragem de dados
- Visualização de dados

https://github.com/rmcesarjr/iccd/blob/main/notebooks/data_science_medicamento_pessao.ipynb



Datasets





Carregamento de dados (data_loaders)

```
RAW_URL = "https://raw.githubusercontent.com/rmcesarjr/iccd/main/data/dados_pressao_local.csv"
#RAW_URL = None # util para ler do proprio hd local
VERBOSE = False
def carrega dados():
    if RAW URL:
        df = pd.read_csv(RAW_URL)
    else:
        uploaded = files.upload()
        nome = next(iter(uploaded))
        df = pd.read_csv(io.BytesIO(uploaded[nome]))
    return df
```



Representação dos dados

```
def carrega_dados():
    if RAW URL:
        df = pd.read csv(RAW URL)
    else:
        uploaded = files.upload()
        nome = next(iter(uploaded))
        df = pd.read_csv(io.BytesIO(uploaded[nome]))
    ids
           = df["ID_paciente"].tolist()
    datas = df["Data"].tolist()
          = df["Sistolica"].tolist()
    sist
    dias
           = df["Diastolica"].tolist()
    glic
           = df["Glicemia"].tolist()
    grupos = df["Grupo"].tolist()
    return ids, datas, sist, dias, glic, grupos
```

Listas

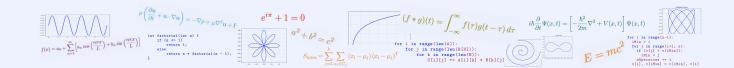
```
def carrega_dados():
    if RAW_URL:
        df = pd.read_csv(RAW_URL)
    else:
        uploaded = files.upload()
        nome = next(iter(uploaded))
        df = pd.read_csv(io.BytesIO(uploaded[nome]))
    return df
```

Data frames



Tabela sumária de dados

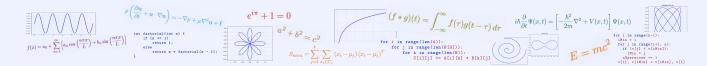
	#Pacientes	(Sistolica, count)	(Sistolica, mean)	(Sistolica, min)	(Sistolica, max)	(Diastolica, count)	(Diastolica, mean)	(Diastolica, min)	(Diastolica, max)	(Glicemia, count)	(Glicemia, mean)	(Glicemia, min)	(Glicemia, max)
Grupo													
Medicamento	100	700	121.4	-40	620	700	78.2	-20	440	700	99.3	-40	450
Nada	100	700	135.7	-40	620	700	91.6	-20	440	700	112.4	-40	450
Placebo	100	700	132.3	-40	620	700	90.5	-20	440	700	114.8	-40	450



Manipulação de dados: controle de qualidade

Ruídos, erros, outliers

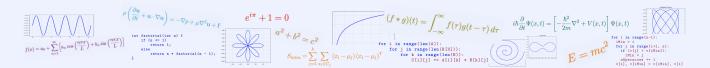
27 4 05/10/2021 129 86 -40 Placebo 28 4 06/10/2021 125 85 102 Placebo 29 4 07/10/2021 116 84 111 Placebo 30 5 13/09/2021 130 84 109 Placebo 31 5 14/09/2021 119 87 108 Placebo 32 5 15/09/2021 118 87 113 Placebo 33 5 16/09/2201 124 87 111 Placebo 34 5 17/09/2021 -40 93 111 Placebo 35 5 18/09/2021 127 82 111 Placebo 36 5 19/09/2021 121 88 116 Placebo 37 6 20/01/2021 126 81 107 Placebo 39 6 21/01/2021 126 85 114 Placebo 40 6 23/01/2021 620 83 118							
29 4 07/10/2021 116 84 111 Placebo 30 5 13/09/2021 130 84 109 Placebo 31 5 14/09/2021 119 87 108 Placebo 32 5 15/09/2021 118 87 113 Placebo 33 5 16/09/2201 124 87 111 Placebo 34 5 17/09/2021 -40 93 111 Placebo 35 5 18/09/2021 127 82 111 Placebo 36 5 19/09/2021 121 88 116 Placebo 37 6 20/01/2021 126 81 107 Placebo 38 6 21/01/2021 128 79 120 Placebo 39 6 22/01/2021 126 85 114 Placebo 40 6 23/01/2021 620 83 118 Placebo 41 6 24/01/2021 120 84 108	27	4	05/10/2021	129	86	-40	Placebo
30 5 13/09/2021 130 84 109 Placebo 31 5 14/09/2021 119 87 108 Placebo 32 5 15/09/2021 118 87 113 Placebo 33 5 16/09/2201 124 87 111 Placebo 34 5 17/09/2021 -40 93 111 Placebo 35 5 18/09/2021 127 82 111 Placebo 36 5 19/09/2021 121 88 116 Placebo 37 6 20/01/2021 126 81 107 Placebo 38 6 21/01/2021 128 79 120 Placebo 39 6 22/01/2021 126 85 114 Placebo 40 6 23/01/2021 620 83 118 Placebo 41 6 24/01/2021 120 84 108 Placebo	28	4	06/10/2021	125	85	102	Placebo
31 5 14/09/2021 119 87 108 Placebo 32 5 15/09/2021 118 87 113 Placebo 33 5 16/09/2201 124 87 111 Placebo 34 5 17/09/2021 -40 93 111 Placebo 35 5 18/09/2021 127 82 111 Placebo 36 5 19/09/2021 121 88 116 Placebo 37 6 20/01/2021 126 81 107 Placebo 38 6 21/01/2021 128 79 120 Placebo 39 6 22/01/2021 126 85 114 Placebo 40 6 23/01/2021 620 83 118 Placebo 41 6 24/01/2021 120 84 108 Placebo	29	4	07/10/2021	116	84	111	Placebo
32 5 15/09/2021 118 87 113 Placebo 33 5 16/09/2201 124 87 111 Placebo 34 5 17/09/2021 -40 93 111 Placebo 35 5 18/09/2021 127 82 111 Placebo 36 5 19/09/2021 121 88 116 Placebo 37 6 20/01/2021 126 81 107 Placebo 38 6 21/01/2021 128 79 120 Placebo 39 6 22/01/2021 126 85 114 Placebo 40 6 23/01/2021 620 83 118 Placebo 41 6 24/01/2021 120 84 108 Placebo	30	5	13/09/2021	130	84	109	Placebo
33 5 16/09/2201 124 87 111 Placebo 34 5 17/09/2021 -40 93 111 Placebo 35 5 18/09/2021 127 82 111 Placebo 36 5 19/09/2021 121 88 116 Placebo 37 6 20/01/2021 126 81 107 Placebo 38 6 21/01/2021 128 79 120 Placebo 39 6 22/01/2021 126 85 114 Placebo 40 6 23/01/2021 620 83 118 Placebo 41 6 24/01/2021 120 84 108 Placebo	31	5	14/09/2021	119	87	108	Placebo
34 5 17/09/2021 -40 93 111 Placebo 35 5 18/09/2021 127 82 111 Placebo 36 5 19/09/2021 121 88 116 Placebo 37 6 20/01/2021 126 81 107 Placebo 38 6 21/01/2021 128 79 120 Placebo 39 6 22/01/2021 126 85 114 Placebo 40 6 23/01/2021 620 83 118 Placebo 41 6 24/01/2021 120 84 108 Placebo	32	5	15/09/2021	118	87	113	Placebo
35 5 18/09/2021 127 82 111 Placebo 36 5 19/09/2021 121 88 116 Placebo 37 6 20/01/2021 126 81 107 Placebo 38 6 21/01/2021 128 79 120 Placebo 39 6 22/01/2021 126 85 114 Placebo 40 6 23/01/2021 620 83 118 Placebo 41 6 24/01/2021 120 84 108 Placebo	33	5	16/09/2201	124	87	111	Placebo
36 5 19/09/2021 121 88 116 Placebo 37 6 20/01/2021 126 81 107 Placebo 38 6 21/01/2021 128 79 120 Placebo 39 6 22/01/2021 126 85 114 Placebo 40 6 23/01/2021 620 83 118 Placebo 41 6 24/01/2021 120 84 108 Placebo	34	5	17/09/2021	-40	93	111	Placebo
37 6 20/01/2021 126 81 107 Placebo 38 6 21/01/2021 128 79 120 Placebo 39 6 22/01/2021 126 85 114 Placebo 40 6 23/01/2021 620 83 118 Placebo 41 6 24/01/2021 120 84 108 Placebo	35	5	18/09/2021	127	82	111	Placebo
38 6 21/01/2021 128 79 120 Placebo 39 6 22/01/2021 126 85 114 Placebo 40 6 23/01/2021 620 83 118 Placebo 41 6 24/01/2021 120 84 108 Placebo	36	5	19/09/2021	121	88	116	Placebo
39 6 22/01/2021 126 85 114 Placebo 40 6 23/01/2021 620 83 118 Placebo 41 6 24/01/2021 120 84 108 Placebo	37	6	20/01/2021	126	81	107	Placebo
40 6 23/01/2021 620 83 118 Placebo 41 6 24/01/2021 120 84 108 Placebo	38	6	21/01/2021	128	79	120	Placebo
41 6 24/01/2021 120 84 108 Placebo	39	6	22/01/2021	126	85	114	Placebo
	40	6	23/01/2021	620	83	118	Placebo
42 6 25/01/2021 133 93 113 Placebo	41	6	24/01/2021	120	84	108	Placebo
20/01/2021 100 000 1100 1100000	42	6	25/01/2021	133	93	113	Placebo



Controle de qualidade: filtragem de dados

```
def controle_qualidade(df, max_preview=10):
    ids = df["ID_paciente"].tolist()
    datas = df["Data"].tolist()
   sistolica = df["Sistolica"].tolist()
   diastolica = df["Diastolica"].tolist()
   glicemia = df["Glicemia"].tolist()
   grupos = df["Grupo"].tolist()
   n = len(ids)
   ids_ok, datas_ok, sist_ok, dia_ok, gli_ok, grupos_ok = [], [], [], [], []
   n bad = 0
   print("=== CONTROLE DE QUALIDADE (data) ===")
   for i in range(n):
        idp = ids[i]
       data = datas[i]
       sis = sistolica[i]
            = diastolica[i]
            = glicemia[i]
       grp = grupos[i]
       ok. motivo = criterios qualidade(data, sis, dia, qli)
       if ok:
           # mantém a amostra
            ids_ok.append(idp)
           datas_ok.append(data)
           sist_ok.append(sis)
           dia ok.append(dia)
           gli_ok.append(gli)
           grupos_ok.append(grp)
           if VERBOSE: print(f"Data invalida excluida da amostra: paciente {idp} motivo {motivo}")
            n_bad+=1
   print(f"Total de amostras: {n}")
   print(f"Removidas: {n_bad} ({(n_bad/n*100):.2f}%)")
   return cria df(ids ok, datas ok, sist ok, dia ok, gli ok, grupos ok)
```

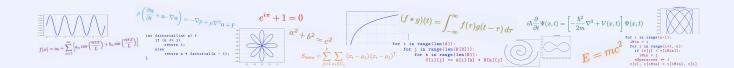
```
def criterios qualidade(data str, sis, dia, gli, ano valido=2021):
  dia min = 30
 dia max = 220
 sis_min = 50
 sis max = 300
 ali min = 60
 gli max = 200
 s = str(data_str).strip()
 partes = s.split("/")
 dd_s, mm_s, aa_s = partes
  dd = int(dd s)
 mm = int(mm_s)
 aa = int(aa s)
  if not (1 \le dd \le 31):
      return False, "Dia fora de [1,31]"
 if not (1 <= mm <= 12):
      return False, "Mês fora de [1,12]"
 if aa != ano valido:
      return False, f"Ano != {ano valido}"
 if not (sis_min <= sis <= sis_max):</pre>
      return False, f"Nao verificado {sis min} ≤ Sistólica ≤ {sis max}"
 if not (dia_min <= dia <= dia_max):</pre>
      return False, f"Nao verificado {dia min} ≤ Diastólica ≤ {dia max}"
 if not (gli min <= gli <= gli max):
      return False, f"Nao verificado {gli_min} ≤ Glicemia ≤ {gli_max}"
  return True, None
```



Controle de qualidade: filtragem de dados

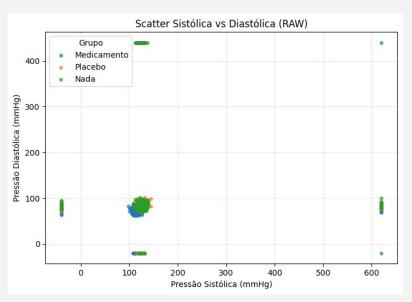
=== CONTROLE DE QUALIDADE (data) === Total de amostras: 2100 Removidas: 397 (18.90%)

Resumo estat	tístico por grup #Pacientes	oo (inclui #Pacie (Sistolica, count)	ntes distintos): (Sistolica, mean)	(Sistolica, min)	(Sistolica, max)	(Diastolica, count)	(Diastolica, mean)	(Diastolica, min)	(Diastolica, max)	(Glicemia, count)	(Glicemia, mean)	(Glicemia, min)	(Glicemia, max)
Grupo													
Medicamento	100	561	115.1	98	130	561	75.2	61	92	561	90.2	74	106
Nada	100	566	125.2	109	140	566	84.9	70	101	566	109.5	94	124
Placebo	100	576	125.4	111	145	576	85.0	72	101	576	110.4	95	125



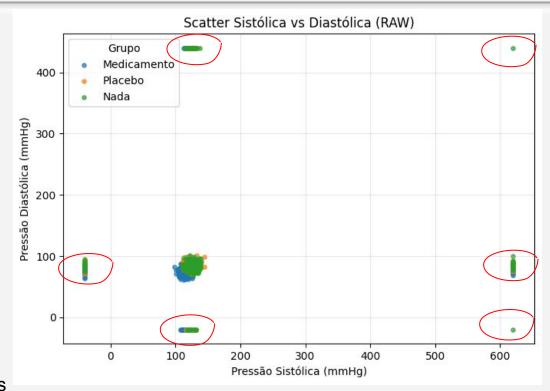
Visualização de dados

```
def visualiza_dados(df, titulo="Scatter Sistólica vs Diastólica por grupo (cor =
   plt.figure(figsize=figure_size())
   for grupo in ["Medicamento", "Placebo", "Nada"]:
        sub = df[df["Grupo"] == grupo]
        plt.scatter(sub["Sistolica"], sub["Diastolica"], s=14, alpha=0.7, label=grupo)
   plt.xlabel("Pressão Sistólica (mmHg)")
   plt.ylabel("Pressão Diastólica (mmHg)")
   plt.title(titulo)
   plt.grid(True, alpha=0.3)
   plt.legend(title="Grupo")
   plt.tight_layout()
   plt.show()
```

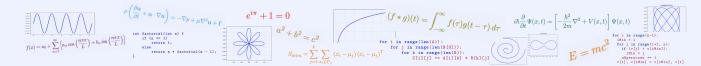




Visualização de dados



Ruídos nos dados

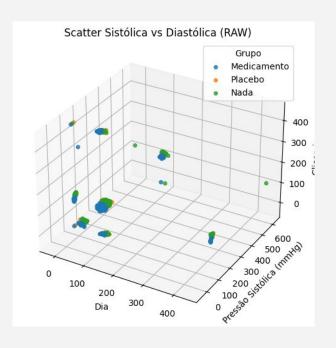


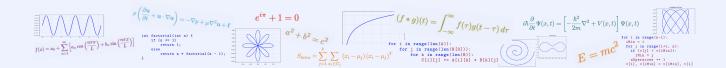
Visualização de dados: 3D

```
fig = plt.figure(figsize=figure_size())
ax = fig.add_subplot(111, projection="3d")

for grupo in ["Medicamento", "Placebo", "Nada"]:
    sub = df[df["Grupo"] == grupo]
    ax.scatter(sub["Diastolica"], sub["Sistolica"], sub["Glicemia"], s=16, alpha=0.8, label=grupo)

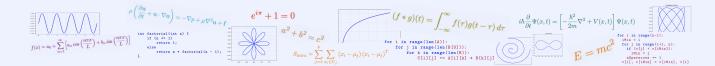
ax.set_xlabel("Dia")
ax.set_ylabel("Pressão Sistólica (mmHg)")
ax.set_zlabel("Glicemia")
ax.set_zlabel("Glicemia")
ax.set_title(titulo)
ax.legend(title="Grupo")
plt.tight_layout()
plt.show()
```

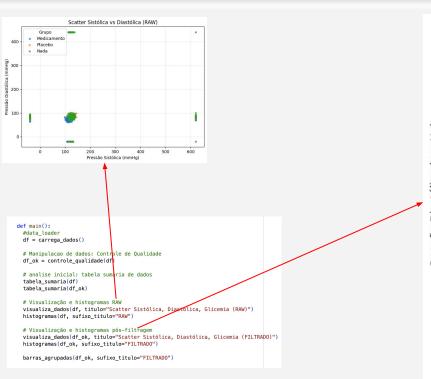


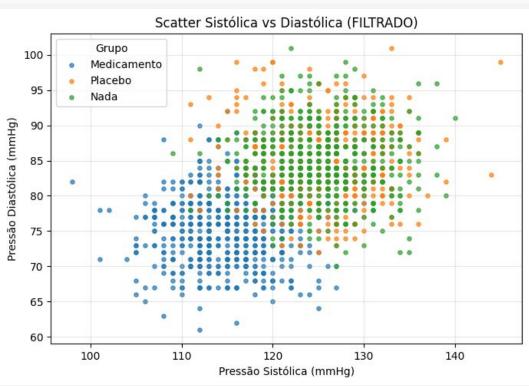


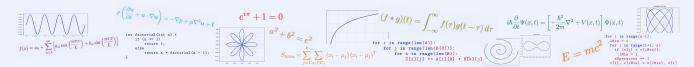
Visualização de dados: 3D

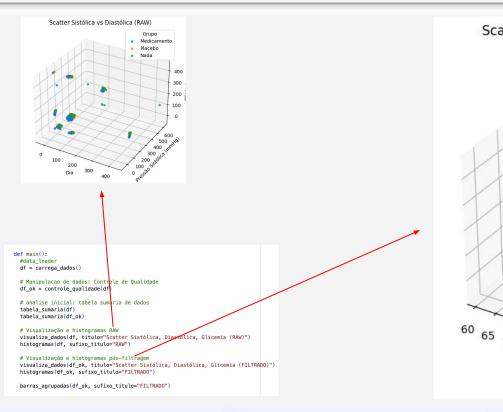
```
def main():
 #data loader
  df = carrega dados()
 # Manipulacao de dados: Controle de Qualidade
  df ok = controle qualidade(df)
 # analise inicial: tabela sumaria de dados
  tabela_sumaria(df)
  tabela sumaria(df ok)
 # Visualização e histogramas RAW
  visualiza_dados(df, titulo="Scatter Sistólica, Diastólica, Glicemia (RAW)")
  histogramas(df, sufixo_titulo="RAW")
 # Visualização e histogramas pós-filtragem
  visualiza_dados(df_ok, titulo="Scatter Sistólica, Diastólica, Glicemia (FILTRADO)")
  histogramas(df_ok, sufixo_titulo="FILTRADO")
  barras agrupadas(df ok, sufixo titulo="FILTRADO")
```

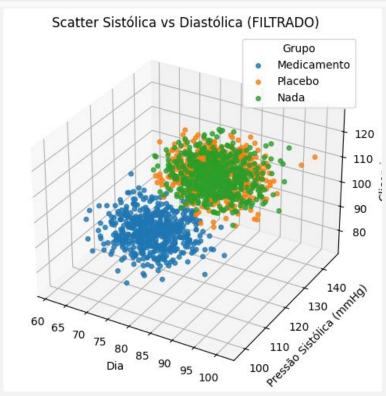






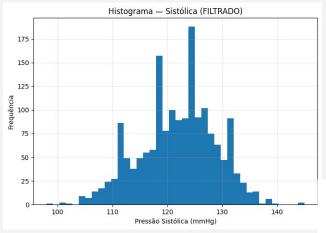








```
def histogramas(df, sufixo titulo="RAW"):
   # Histograma Sistólica
   plt.figure(figsize=figure size())
   plt.hist(df["Sistolica"].dropna(), bins=40)
   plt.xlabel("Pressão Sistólica (mmHg)")
   plt.ylabel("Frequência")
   plt.title(f"Histograma - Sistólica ({sufixo titulo})")
   plt.grid(True, alpha=0.3)
   plt.tight_layout()
   plt.show()
   # Histograma Diastólica
   plt.figure(figsize=figure_size())
   plt.hist(df["Diastolica"].dropna(), bins=40)
   plt.xlabel("Pressão Diastólica (mmHg)")
   plt.vlabel("Frequência")
   plt.title(f"Histograma - Diastólica ({sufixo titulo})")
   plt.grid(True, alpha=0.3)
   plt.tight_layout()
   plt.show()
   # Histograma Glicemia
   plt.figure(figsize=figure_size())
   plt.hist(df["Glicemia"].dropna(), bins=40)
   plt.xlabel("Glicemia")
   plt.ylabel("Frequência")
   plt.title(f"Histograma - Glicemia ({sufixo_titulo})")
   plt.grid(True, alpha=0.3)
   plt.tight layout()
   plt.show()
```



Potencial e facilidade de uso

